

ESERCIZIO 1: Regressione Polinomiale

Luca Cristofanilli 1999520

October 1, 2025

1 Regressione Polinomiale from scratch

Per un fit lineare ho:

$$y_\mu = f^{(1)}(x_\mu, \{\vec{\theta}\}) + \eta_\mu = \theta_0 + \theta_1 x_\mu + \eta_\mu \quad (1)$$

Nel caso di un polinomio generico di grado α , contenente $\alpha + 1$ parametri:

$$y_\mu = f^\alpha(x_\mu, \{\vec{\theta}\}) = \vec{X}_\mu \cdot \vec{\theta} + \eta_\mu \quad (2)$$

dove $\vec{X}_\mu$ è un vettore che contiene $\alpha + 1$ elementi $\vec{X}_\mu = (1, x_\mu, x_\mu^2, \dots, x_\mu^\alpha)$ e $\vec{\theta}$ è il vettore dei pesi. Utilizzo il teorema di Bayes per cercare la distribuzione a posteriori dei pesi.

$$P(\{\vec{\theta}\}|\{x_\mu, y_\mu\}) = \frac{P(\{x_\mu, y_\mu\}|\{\vec{\theta}\})P(\{\vec{\theta}\})}{P(\{x_\mu, y_\mu\})} \quad (3)$$

Cerco i parametri $\{\vec{\theta}\}$ che massimizzano il termine a sinistra. Dato che η_μ è un valore gaussiano a media $\mu = 0$ e varianza σ e i dati $\{x_\mu, y_\mu\}$ sono indipendenti tra loro, la distribuzione:

$$P(\{x_\mu, y_\mu\}|\{\vec{\theta}\}) = \prod_{\mu=1}^P \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(y_\mu - \vec{X}_\mu \cdot \vec{\theta})^2}{2\sigma^2}\right) \quad (4)$$

Massimizzare $P(\{\vec{\theta}\}|\{x_\mu, y_\mu\})$ rispetto ai parametri significa (per la monotonia del logaritmo):

$$\max_{\vec{\theta}} P(\{\vec{\theta}\}|\{x_\mu, y_\mu\}) = \max_{\vec{\theta}} \log(P(\{\vec{\theta}\}|\{x_\mu, y_\mu\})) \propto -\sum_{\mu=1}^P (y_\mu - \vec{X}_\mu \cdot \vec{\theta})^2 \quad (5)$$

$$\max_{\vec{\theta}} P(\{\vec{\theta}\}|\{x_\mu, y_\mu\}) = \min_{\vec{\theta}} \sum_{\mu=1}^P (y_\mu - \vec{X}_\mu \cdot \vec{\theta})^2 = \min_{\vec{\theta}} L(\{x_\mu, y_\mu\}, \{\vec{\theta}\}) \quad (6)$$

Dove $L(\{x_\mu, y_\mu\}, \{\vec{\theta}\}) = \frac{1}{2} \sum_{\mu=1}^P (y_\mu - \vec{X}_\mu \cdot \vec{\theta})^2$ Posso riscrivere $L(\{x_\mu, y_\mu\}, \{\vec{\theta}\})$ come la norma di un vettore che ha come righe i singoli $y_\mu - \vec{X}_\mu \cdot \vec{\theta}$, cioè:

$$L(\{x_\mu, y_\mu\}, \{\vec{\theta}\}) = \frac{1}{2} (\vec{y} - X\vec{\theta}) \cdot (\vec{y} - X\vec{\theta}) = \frac{1}{2} (\vec{y} - X\vec{\theta})^T (\vec{y} - X\vec{\theta}) \quad (7)$$

dove $\vec{y}$ è un vettore in $\mathbb{R}^P$, $\vec{\theta}$ è un vettore in $\mathbb{R}^{\alpha+1}$ e X è una matrice $P \times (\alpha + 1)$.

Calcolando il gradiente:

$$\nabla_{\vec{\theta}} L(\{x_\mu, y_\mu\}, \{\vec{\theta}\}) = \sum_{\mu=1}^P -\vec{X}_\mu (y_\mu - \vec{X}_\mu \cdot \vec{\theta}) = -(\vec{y} - X\vec{\theta})^T X = \vec{\theta}^T X^T X - \vec{y}^T X = \vec{0} \quad (8)$$

Traspongo e inverte per ricavare $\vec{\theta}$:

$$X^T X \vec{\theta} - X^T \vec{y} = \vec{0} \quad (9)$$

$$\vec{\theta} = X^{-1} (X^T)^{-1} X^T \vec{y} = (X^T X)^{-1} X^T \vec{y} \quad (10)$$

Quindi il valore di $\vec{\theta}$ ottimale è dato da:

$$\vec{\theta}^* = (X^T X)^{-1} X^T \vec{y} \quad (11)$$

Con $\vec{y}$ il vettore dei target y_μ e X la matrice i cui elementi sono dati da $X_{\mu\nu} = x_\mu^{\nu-1}$. Nel calcolo numerico per il set di pesi ottimali, per garantire stabilità numerica durante il calcolo dell'inversa, in realtà viene aggiunto un secondo addendo a $X^T X$ che diventa $X^T X + \epsilon I$. Questo garantisce l'esistenza di una matrice inversa anche per sistemi con $X^T X$ singolari, ma aggiunge una seconda condizione: tra tutti i pesi possibili, nel caso in cui il sistema sia singolare, si sceglie quello con norma dei pesi minore. Questo equivale ad assumere una distribuzione a priori gaussiana per il valore dei pesi.

2 Generazione dei dati sintetici

In tutti gli esperimenti consideriamo due funzioni $f_A(x) = 2x$ e $f_B(x) = 2x - 10x^5 + 15x^{10}$ che utilizziamo per generare dei dati sintetici con cui fittare tre polinomi rispettivamente di grado 1, 3 e 10. Generiamo P punti per il train set e P_{test} punti per il test set. I valori x_μ sono campionati uniformemente nell'intervallo $[0 : 1]$ per il train set e $[0 : 1.25]$ nel test set, e vengono poi utilizzati per calcolare i valori di y_μ attraverso le funzioni f_A e f_B con l'aggiunta di rumore gaussiano η_μ con $\langle \eta_\mu \rangle$ e $\langle \eta_\mu \eta_\nu \rangle = \delta_{\mu\nu} \sigma^2$, cioè $y_\mu = f_J(x_\mu) + \eta_\mu$.

3 Prima simulazione

Nella prima simulazione generiamo come train set $P = 10$ punti e come test set $P_{test} = 20$ con $\sigma = 0$. Con varianza nulla il problema di best fit diventa un problema di interpolazione esatta. Di seguito i risultati della simulazione per le funzioni f_A e f_B , ognuna con i tre diversi modelli polinomiali.




Figure 1: Fit dei dati prodotti con f_A con un polinomio di grado 1. Train set e test set con errore di ricostruzione MSE.




Figure 2: Fit dei dati prodotti con f_A con un polinomio di grado 3. Train set e test set con errore di ricostruzione MSE.




Figure 3: Fit dei dati prodotti con f_A con un polinomio di grado 10. Train set e test set con errore di ricostruzione MSE.

Con tutti i modelli il fit riesce a estrapolare correttamente anche nell'intervallo $[1 : 1.25]$ (sebbene ampliando ulteriormente l'intervallo l'accuratezza dell'interpolazione tenda a ridursi), persino nel caso $\alpha = 10$, in cui il numero di gradi di libertà supera quello dei vincoli. Ciò è dovuto alla semplicità del task. Poiché i dati giacciono su una funzione lineare (un polinomio di grado 1), la soluzione a norma minima trovata dall'algoritmo nel caso $\alpha = 10$ corrisponde proprio alla retta stessa, annullando di fatto l'effetto dei coefficienti di grado superiore.

La situazione è differente per i punti generati con la funzione f_B , dove il task è molto più complicato e finché non si utilizza un numero abbastanza elevato di gradi di libertà il fit fallisce completamente.




Figure 4: Fit dei dati prodotti con f_B con un polinomio di grado 1. Train set e test set con errore di ricostruzione MSE.




Figure 5: Fit dei dati prodotti con f_B con un polinomio di grado 3. Train set e test set con errore di ricostruzione MSE.




Figure 6: Fit dei dati prodotti con f_B con un polinomio di grado 10. Train set e test set con errore di ricostruzione MSE.

In questo caso per $\alpha = 1, 3$ non ci sono abbastanza parametri per interpolare tutti i P punti, mentre per $\alpha = 10$ c'è un parametro in più rispetto al numero totale di punto, questo implica che ci sono infinite curve che interpolano correttamente, ma a causa del fattore di regolarizzazione viene scelta quella con la norma dei pesi più bassa.

4 Seconda simulazione

Ripetiamo l'esperimento con $P = 100$, $P_{test} = 20$ e $\sigma = 1$. Di seguito i risultati della simulazione per f_A e f_B .




Figure 7: Fit dei dati prodotti con f_A con un polinomio di grado 1, $\sigma = 1$. Train set e test set con errore di ricostruzione MSE.




Figure 8: Fit dei dati prodotti con f_A con un polinomio di grado 3, $\sigma = 1$. Train set e test set con errore di ricostruzione MSE.

L'aggiunta di rumore con una $\sigma = 1$, con un numero relativamente basso di esempi $P = 100$, provoca un inevitabile overfitting nei modelli con $\alpha = 3, 10$. Con $\alpha = 1$ il numero di gradi di libertà è troppo basso per overfittare il rumore.




Figure 9: Fit dei dati prodotti con f_A con un polinomio di grado 10, $\sigma = 1$. Train set e test set con errore di ricostruzione MSE.




Figure 10: Fit dei dati prodotti con f_B con un polinomio di grado 1, $\sigma = 1$. Train set e test set con errore di ricostruzione MSE.




Figure 11: Fit dei dati prodotti con f_B con un polinomio di grado 3, $\sigma = 1$. Train set e test set con errore di ricostruzione MSE.




Figure 12: Fit dei dati prodotti con f_B con un polinomio di grado 10, $\sigma = 1$. Train set e test set con errore di ricostruzione MSE.

5 Simulazione 3

Ripetiamo l'esperimento una ulteriore volta con $P = 10000$, $P_{test} = 100$ e $\sigma = 1$. Di seguito i risultati della simulazione per f_A e f_B .




Figure 13: Fit dei dati prodotti con f_A con un polinomio di grado 1, $\sigma = 1$, $P = 10000$. Train set e test set con errore di ricostruzione MSE.




Figure 14: Fit dei dati prodotti con f_A con un polinomio di grado 3, $\sigma = 1$, $P = 10000$. Train set e test set con errore di ricostruzione MSE.

Empiricamente si osserva che con l'aggiunta del rumore, per evitare un overfitting eccessivo è necessario mostrare al modello molti più esempi, cioè aumentare di molto la taglia del dataset. In particolare fittando con $\alpha = 10$ i punti ottenuti da $f_B(x)$ si riesce anche ad estrapolare correttamente nell'intervallo di test.




Figure 15: Fit dei dati prodotti con f_A con un polinomio di grado 10, $\sigma = 1$, $P = 10000$. Train set e test set con errore di ricostruzione MSE.




Figure 16: Fit dei dati prodotti con f_A con un polinomio di grado 1, $\sigma = 1$, $P = 10000$. Train set e test set con errore di ricostruzione MSE.




Figure 17: Fit dei dati prodotti con f_A con un polinomio di grado 3, $\sigma = 1$, $P = 10000$. Train set e test set con errore di ricostruzione MSE.




Figure 18: Fit dei dati prodotti con f_A con un polinomio di grado 10, $\sigma = 1$, $P = 10000$. Train set e test set con errore di ricostruzione MSE.