

ESERCIZIO 3: La regola di apprendimento del perceptron randomizzato

Luca Cristofanilli 1999520

October 17, 2025

1 Generazione dei dati sintetici

I dati sintetici per l'addestramento e il test dei modelli sono costituiti da P coppie di numeri interi, campionati casualmente nell'intervallo $[0 : 1023]$. Le labels sono generate dal Teacher J^* che corrisponde al perceptron che risolve perfettamente il problema della classificazione dei due numeri. Queste assumono valore $+1$ se il primo numero è maggiore del secondo e -1 nel caso opposto. Per assicurare che il problema di classificazione sia sempre ben definito, ogni coppia deve contenere numeri distinti. La procedura di generazione garantisce questa condizione scartando e rigenerando iterativamente qualsiasi coppia in cui i due numeri risultino identici, fino a ottenere un dataset completo di P esempi unici.

2 Descrizione della simulazione

L'esperimento numerico consiste nello studio dell'andamento dell'errore medio di generalizzazione $\langle \epsilon \rangle$ di un Perceptron, inizializzato casualmente, in funzione del numero di elementi nel dataset di training P .

2.1 Addestramento dello Student

Il Perceptron è stato addestrato utilizzando la seguente regola: se la predizione del perceptron è differente dalla label assegnata dal Teacher $\sigma(\vec{\xi}^\mu, \vec{J}) \neq \sigma_T^\mu$, aggiorniamo il vettore dei pesi sinaptici $\vec{J}(t+1) = \vec{J}(t) + \frac{1}{\sqrt{N}} \sigma_T^\mu \vec{\xi}^\mu \cdot (1 + r_i)$, dove r_i è un numero casuale estratto da una distribuzione gaussiana a media $\mu = 0$ e varianza $\sigma^2 = 50$. Questo ciclo di addestramento viene ripetuto su tutto il dataset di training varie volte finché l'errore di classificazione non scende a zero $\epsilon_t = 0$.

2.2 Studio dell'errore di generalizzazione medio

Valuto l'errore di generalizzazione dello Student i -esimo dopo il processo di addestramento come $\epsilon_i = \frac{1}{P_{test}} \sum_{\mu=1}^{P_{test}} \theta(-\sigma(\vec{S}^\mu, \vec{J}) \sigma_T^\mu)$, con $P_{test} = 1000$. Ripeto questo processo di addestramento e valutazione per $N_{runs} = 1000$ volte, al variare della dimensione del vettore di pesi sinaptici N e al variare della taglia del dataset di training P . Infine, stimo l'errore di generalizzazione medio $\bar{\epsilon} = \frac{1}{N_{runs}} \sum_{i=1}^{N_{runs}} \epsilon_i$ e la sua deviazione standard $\sigma_\epsilon = \frac{1}{N_{runs}-1} \sum_{i=1}^{N_{runs}} (\epsilon_i - \bar{\epsilon})^2$ per $N = 20, 40$ e $P_{20} = [1, 10, 20, 50, 100, 150, 200]$, $P_{40} = [1, 2, 20, 40, 100, 200, 300]$.

3 Considerazioni teoriche

Nel caso dell'apprendimento di Gibbs a temperatura nulla, addestrare uno Student su un dataset di P punti, equivale a campionare randomicamente dal version space $\Omega_P(\epsilon)$. Facendo un ragionamento approssimato, abbiamo dedotto che in media il volume (numero) di studenti compatibili con errore di generalizzazione ϵ , dopo essere stati addestrati su P punti è dato da:

$$\Omega_P(\epsilon) = \Omega_0(\epsilon)(1 - \epsilon)^P$$

Dove $\Omega_0(\epsilon)$ è il volume dei vettori sinaptici con overlap $R = \cos(\pi\epsilon)$ prima che il training abbia inizio. Questo volume è pari a

$$\Omega_0(\epsilon) = \frac{2\pi^{\frac{N-1}{2}}}{\Gamma\left(\frac{N-1}{2}\right)} \left(\sin(\pi\epsilon)\sqrt{N}\right)^{N-2}$$

Campionando casualmente nello spazio delle versioni, la probabilità di estrarre uno studente con errore di generalizzazione ϵ è proporzionale a $\Omega_P(\epsilon)$. Chiamo questa probabilità

$$P(\epsilon; N, P) = \frac{\Omega_P(\epsilon)}{\int_0^1 d\eta \Omega_P(\eta)}$$

Posso riscrivere $\Omega_P(\epsilon)$ come segue:

$$\Omega_P(\epsilon) = C_N \exp \{(N-2) \log(\sin(\pi\epsilon)) + P \log(1-\epsilon)\} \simeq C_N \exp \left\{ N \left[\log(\sin(\pi\epsilon)) + \frac{P}{N} \log(1-\epsilon) \right] \right\}$$

Quindi è evidente che nel limite per $N \gg 1$ la distribuzione di probabilità sarà dominata dal massimo della funzione all'interno della parentesi quadra. Valuto questo valore ϵ^* in funzione della quantità $\alpha = \frac{P}{N}$.

$$\pi \cot(\pi\epsilon) - \frac{\alpha}{1-\epsilon} = 0$$

Nel limite termodinamico il valore medio dell'errore di generalizzazione $\langle \epsilon \rangle$ sarà dominato dal valore in cui è maggiormente piccata la distribuzione di probabilità $P(\epsilon; N, P)$.

$$\langle \epsilon \rangle = \epsilon^*(\alpha)$$

Sembrerebbe quindi che il parametro corretto da utilizzare per effettuare un plot dell'errore medio di generalizzazione non sia P ma $\alpha = \frac{P}{N}$.

3.1 Confronto con i dati sperimentali

Le curve teoriche non si sovrappongono a quelle sperimentali. Nel nostro modello basiamo la distribuzione di probabilità sul volume medio degli studenti compatibili, che molto probabilmente non rappresenta in modo fedele l'andamento tipico di questa quantità. Di seguito l'andamento dell'errore di generalizzazione medio sia in funzione del solo numero di esempi nel dataset di training P , sia in funzione del parametro $\alpha = P/N$. Le curve sperimentali sono confrontate con l'andamento teorico previsto dal nostro modello. Le curve teoriche sono corrette a meno di ordini $O\left(\frac{1}{N}\right)$, dato che non sono state ottenute risolvendo numericamente gli integrali, ma utilizzando il metodo di Laplace.




Figure 1: Andamento dell'errore medio di generalizzazione simulato, in funzione di P per $N = 20$ e $N = 40$. Su ogni punto per ragioni di visualizzazione viene presentato l'errore campionario e non l'errore sul valor medio. Gli andamenti sperimentali sono confrontati con l'andamento teorico ottenuto nella sezione 3.

Errore di Generalizzazione: Confronto Sperimentale vs Teorico in funzione di α




Figure 2: Andamento dell'errore medio di generalizzazione simulato, in funzione di $\alpha = P/N$ per $N = 20$ e $N = 40$. Su ogni punto per ragioni di visualizzazione viene presentato l'errore campionario e non l'errore sul valor medio. Gli andamenti sperimentali sono confrontati con l'andamento teorico ottenuto nella sezione 3.