

ESERCIZIO 4: La soluzione annealed per l'apprendimento di un perceptron random.

Luca Cristofanilli 1999520

October 26, 2025

1 Conto annealed

In accordo con il conto annealed, lo studente tipico che raggiunge l'errore di training nullo, raggiunge un errore di generalizzazione $\epsilon(\alpha)$ tale che:

$$\alpha = (1 - \epsilon)\pi \cot(\pi\epsilon) \quad (1)$$

Per risolvere esplicitamente l'equazione (1) è possibile impostare una procedura iterativa per l'equazione riscritta nella forma $\epsilon = f(\epsilon, \alpha)$. La regola ricorsiva è la seguente: iniziare la dinamica in un punto ϵ_0 e proseguire valutando $\epsilon_{i+1} = (1 - a)\epsilon_i + af(\epsilon_i, \alpha)$. Infine, è fondamentale studiare la dinamica di ϵ_i per assicurarsi della sua convergenza.

2 Considerazioni teoriche

Prima di tutto bisogna assicurarsi che $\epsilon^* = \epsilon(\alpha)$ sia effettivamente un punto fisso della mappa iterativa. Per brevità chiamo il membro di destra della regola iterativa come $G_a(\epsilon_i, \alpha)$, in questo modo la regola di evoluzione è data da $\epsilon_{i+1} = G_a(\epsilon_i, \alpha)$. Un punto fisso è tale da rimanere invariato sotto la regola di evoluzione, cioè $\epsilon^* = G_a(\epsilon^*, \alpha)$. Cercando i punti fissi della mappa, cioè quelli che soddisfano la condizione precedente, si ottiene $\epsilon^* = (1 - a)\epsilon^* + af(\epsilon^*, \alpha)$, da cui:

$$\epsilon^* = f(\epsilon^*, \alpha)$$

Quindi la mappa iterativa così costruita ammette effettivamente come punto fisso un punto che risolve l'equazione (1).

Cerco una condizione per la convergenza della mappa e studio l'andamento della distanza tra ϵ_i e ϵ^* allo scorrere dei passi. Affinché la mappa converga a ϵ^* , mi aspetto che nel limite di i abbastanza grande la distanza $\epsilon_i - \epsilon^* = \delta_i$ sia piccola. Sviluppo la legge di evoluzione attorno a ϵ^* per δ_i piccoli:

$$\epsilon_{i+1} = (1 - a)\epsilon_i + a(f(\epsilon^*, \alpha) + f'(\epsilon^*, \alpha)\delta_i) + O(\delta_i^2)$$

Utilizzando la condizione di punto fisso $f(\epsilon^*, \alpha) = \epsilon^*$ e sottraendo ϵ^* da entrambi i membri si ottiene:

$$\epsilon_{i+1} - \epsilon^* = (1 - a)\epsilon_i + a\epsilon^* + af'(\epsilon^*, \alpha)\delta_i - \epsilon^* + O(\delta_i^2)$$

Chiamo $\delta_{i+1} = \epsilon_{i+1} - \epsilon^*$ e raccolgo a fattore comune nel membro di destra ottenendo:

$$\delta_{i+1} = ((1 - a) + af'(\epsilon^*, \alpha))\delta_i + O(\delta_i^2) = \lambda\delta_i + O(\delta_i^2)$$

dove $\lambda = (1 - a) + af'(\epsilon^*, \alpha)$. Quindi, a meno di errori piccoli, la mappa originale si trasforma in una mappa lineare per gli errori δ_i . La convergenza della mappa originale è implicata dalla convergenza a zero della mappa degli errori. Affinché si abbia la convergenza a zero, cioè la seguente condizione

$$\lim_{t \rightarrow \infty} \delta_t = \lim_{t \rightarrow \infty} \lambda^t \delta_0 = 0 \quad (2)$$

è necessario che $|\lambda| < 1$, ma λ è proprio $\frac{\partial}{\partial \epsilon} G_a(\epsilon, \alpha)|_{\epsilon^*}$. Quindi la condizione necessaria di convergenza è:

$$\left| \frac{\partial}{\partial \epsilon} G_a(\epsilon, \alpha) \right|_{\epsilon^*} < 1 \quad (3)$$

3 Scelta della $f(\epsilon, \alpha)$

Le due possibili scelte di $f(\epsilon, \alpha)$ sono:

- $f_1(\epsilon, \alpha) = 1 - \frac{\alpha}{\pi} \tan(\pi\epsilon)$
- $f_2(\epsilon, \alpha) = \frac{1}{\pi} \arctan(\frac{\pi}{\alpha}(1 - \epsilon))$

che si ottengono rispettivamente esplicitando l'equazione (1) rispetto alla ϵ fuori dalla funzione $\cot()$ e dentro. Valuto l'andamento della derivata di $G_a(\epsilon, \alpha)$ nell'intervallo di interesse dei parametri.

3.1 $f_1(\epsilon, \alpha)$

Nel caso della f_1 la condizione di convergenza si traduce in:

$$\left| 1 - a \left(1 + \frac{\alpha}{\cos^2(\pi\epsilon^*)} \right) \right| < 1$$

Questa condizione equivale ad un sistema di due disequazioni. La prima ($G'_a(\epsilon^*, \alpha) < 1$), nel nostro range di parametri ($a > 0, \alpha > 0$) è verificata per ogni valore di ϵ^* , considerando che questo è compreso in $[0 : \frac{1}{2}]$. Infatti, dopo le varie semplificazioni si ha:

$$1 + \frac{\alpha}{\cos^2(\pi\epsilon^*)} > 0$$

che è sempre verificata per ϵ^* nell'intervallo di interesse.

L'altra disequazione ($G'_a(\epsilon^*, \alpha) > -1$) in generale, fissato a in $(0 : 1)$, non è sempre soddisfatta e il suo valore dipende dalla scelta di α . Questo è il motivo dell'instabilità e della non convergenza della dinamica con la scelta f_1 .

3.2 $f_2(\epsilon, \alpha)$

Al contrario la funzione f_2 presenta un comportamento più ottimale. Infatti andando a studiare la convergenza di questa seconda mappa si ha:

$$\left| 1 - a \left(1 + \frac{\alpha}{\alpha^2 + \pi^2(1 - \epsilon^*)^2} \right) \right| < 1$$

La prima disuguaglianza ($G'_a(\epsilon^*, \alpha) < 1$), dopo le dovute semplificazioni, è la seguente:

$$1 + \frac{\alpha}{\alpha^2 + \pi^2(1 - \epsilon^*)^2} > 0$$

Quest'ultima è sempre verificata per qualsiasi valore di $a > 0$ e $\alpha > 0$. La seconda disuguaglianza ($G'_a(\epsilon^*, \alpha) > -1$) è la seguente:

$$\frac{\alpha}{\alpha^2 + \pi^2(1 - \epsilon^*)^2} < \frac{2 - a}{a}$$

che per a compreso in $(0 : 1)$ e ϵ^* compreso in $[0 : \frac{1}{2}]$ è verificata per qualsiasi valore di α . Quindi, mantenendo il parametro a nell'intervallo $(0 : 1)$, la condizione di convergenza della mappa è soddisfatta.

4 Confronto tra le due dinamiche

Di seguito è riportata una figura in cui vengono messe a confronto le dinamiche di evoluzione delle due mappe, con la stessa condizione iniziale pari a $\epsilon_0 = 0.25$ e con la stessa $\alpha = 5$ per diversi valori del parametro $a = 0.1, a = 0.5$ e $a = 0.9$.

L'evoluzione di ϵ_i con la funzione f_1 raggiunge dei picchi estremamente distanti dal punto fisso (indicato dalla linea tratteggiata e calcolato utilizzando metodi numerici differenti), che raggiungono valori $O(10^3)$. Al contrario, l'evoluzione con f_2 è molto stabile e converge velocemente al punto fisso. In teoria potrebbe essere utile studiare ulteriormente la seconda disequazione nella sezione (3.2) al

Confronto Dinamiche di Convergenza per $\alpha = 5$ e $\epsilon_0 = 0.25$




Figure 1: Andamento di ϵ_i in funzione dell'indice di iterazione i , con $\epsilon_0 = 0.25$, $\alpha = 5$ e $a = 0.1$, $a = 0.5$ e $a = 0.9$. Come era atteso da considerazioni teoriche la funzione f_1 non garantisce la convergenza al punto fisso al contrario della funzione f_2 .

variare di α . Valutando l'estremo superiore del membro di sinistra è possibile trovare analiticamente il valore ottimale del parametro a per la massima velocità di convergenza per ogni α . In conclusione, la funzione migliore per risolvere in modo iterativo l'equazione (1) è f_2 . Di seguito un grafico che mette a confronto la curva ottenuta in modo parametrico, quella ottenuta tramite procedura iterativa e quella ottenuta tramite i dati sperimentali.

Confronto Avanzato: Dati Sperimentali vs Teorie




Figure 2: Andamento di $\langle \epsilon \rangle$ in funzione di α . Confronto tra esperimenti realizzati per $N = 20$ e $N = 40$, e le curve teoriche: una ottenuta in modo parametrico, l'altra ottenuta dai punti fissi della mappa costruita con la funzione f_2 al variare di α ($a = 0.9$). La barra di errore dei punti medi è più piccola dei marker stessi.

Le curve teoriche non si sovrappongono a quelle sperimentali. Nel nostro esperimento, addestrare

un certo studente con dataset casuali e rumore molto ampio durante il processo, equivale a campionare randomicamente dallo spazio delle versioni. La probabilità di campionare uno studente con errore di generalizzazione ϵ è quindi proporzionale al volume di quella relativa regione nello spazio delle versioni. Questo volume, a dataset fissato, coinvolge il prodotto di P contributi random; di conseguenza la media rispetto a tutti i possibili dataset (il rumore), per estrapolarne il comportamento tipico, non è un buon approccio, dato che per il prodotto di quantità random non vale il teorema del limite centrale, al contrario della loro somma.