

ESERCIZIO 5: La soluzione quenched per l'apprendimento di un perceptron random.

Luca Cristofanilli 1999520

November 9, 2025

1 Conto quenched

In accordo con il conto quenched, lo studente tipico che raggiunge l'errore di training nullo, raggiunge un overlap con il teacher $R(\alpha)$ tale che:

$$\frac{R}{\sqrt{1-R}} = \frac{\alpha}{\pi} I(R) \quad (1)$$

dove

$$I(R) = \int_{-\infty}^{+\infty} \frac{dv}{\sqrt{2\pi}} \frac{\exp(-(1+R)v^2/2)}{H(-\sqrt{R}v)}$$

e

$$H(u) = \int_u^{+\infty} \frac{dx}{\sqrt{2\pi}} \exp(-x^2/2)$$

L'errore di generalizzazione e l'overlap sono collegati dalla relazione $R(R) = \frac{1}{\pi} \arccos(R)$.

Per risolvere esplicitamente l'equazione (1), è possibile impostare una procedura iterativa per l'equazione riscritta nella forma $R = f(R, \alpha)$. La regola ricorsiva è la seguente: iniziare la dinamica in un punto R_0 e proseguire valutando $R_{i+1} = (1-a)R_i + af(R_i, \alpha)$. Infine, è fondamentale studiare la dinamica di R_i per assicurarsi della sua convergenza.

2 Considerazioni teoriche

Prima di tutto bisogna assicurarsi che $R^* = R(\alpha)$ sia effettivamente un punto fisso della mappa iterativa. Per brevità chiamo il membro di destra della regola iterativa come $g_a(R_i, \alpha)$, in questo modo la regola di evoluzione è data da $R_{i+1} = g_a(R_i, \alpha)$. Un punto fisso è tale da rimanere invariato sotto la regola di evoluzione, cioè $R^* = g_a(R^*, \alpha)$. Cercando i punti fissi della mappa, cioè quelli che soddisfano la condizione precedente, si ottiene $R^* = (1-a)R^* + af(R^*, \alpha)$, da cui:

$$R^* = f(R^*, \alpha)$$

Quindi, la mappa iterativa così costruita ammette effettivamente come punto fisso un punto che risolve l'equazione (1).

Cerco una condizione per la convergenza della mappa e studio l'andamento della distanza tra R_i e R^* allo scorrere dei passi. Affinché la mappa converga a R^* , mi aspetto che nel limite di i abbastanza grande la distanza $R_i - R^* = \delta_i$ sia piccola. Sviluppo la legge di evoluzione attorno a R^* per δ_i piccoli:

$$R_{i+1} = (1-a)R_i + a(f(R^*, \alpha) + f'(R^*, \alpha)\delta_i) + O(\delta_i^2)$$

Utilizzando la condizione di punto fisso $f(R^*, \alpha) = R^*$ e sottraendo R^* da entrambi i membri si ottiene:

$$R_{i+1} - R^* = (1-a)R_i + aR^* + af'(R^*, \alpha)\delta_i - R^* + O(\delta_i^2)$$

Chiamo $\delta_{i+1} = R_{i+1} - R^*$ e raccolgo a fattore comune nel membro di destra ottenendo:

$$\delta_{i+1} = ((1-a) + af'(R^*, \alpha))\delta_i + O(\delta_i^2) = \lambda\delta_i + O(\delta_i^2)$$

dove $\lambda = (1 - a) + af'(R^*, \alpha)$. Quindi, a meno di errori piccoli, la mappa originale si trasforma in una mappa lineare per gli errori δ_i . La convergenza della mappa originale è implicata dalla convergenza a zero della mappa degli errori. Affinché si abbia la convergenza a zero, cioè la seguente condizione

$$\lim_{t \rightarrow \infty} \delta_t = \lim_{t \rightarrow \infty} \lambda^t \delta_0 = 0 \quad (2)$$

è necessario che $|\lambda| < 1$, ma λ è proprio $\frac{\partial}{\partial R} g_a(R, \alpha)|_{R^*}$. Quindi la condizione necessaria di convergenza è:

$$\left| \frac{\partial}{\partial R} g_a(R, \alpha) \right|_{R^*} < 1 \quad (3)$$

Il valore di λ che massimizza la velocità di convergenza è $\lambda = 0$. In questo modo, per ogni R^* , è possibile calcolare il valore teorico di a ottimale (a_{opt}).

$$a_{opt} = \frac{1}{1 - f'(R^*, \alpha)}$$

3 Scelta della $f(R, \alpha)$

Le due possibili scelte di $f(R, \alpha)$ sono:

- $f_1(R, \alpha) = \frac{\alpha}{\pi} \sqrt{1 - R} I(R)$
- $f_2(R, \alpha) = 1 - \frac{\pi^2 R^2}{\alpha^2 I(R)^2}$

che si ottengono rispettivamente esplicitando l'equazione (1) rispetto alla R al numeratore e quella all'interno della radice nel denominatore nel membro di sinistra.

4 Confronto tra le due dinamiche

Di seguito è riportata una figura in cui vengono messe a confronto le dinamiche di evoluzione delle due mappe, con la stessa condizione iniziale pari a $R_0 = 0.5$ e con la stessa $a = 0.5$ costante, per diversi valori del parametro $\alpha = 0.1, 5.0$.

Confronto Dinamiche per $\alpha = 0.1$ e $x_0 = 0.5$




Figure 1: Andamento di R_i in funzione dell'indice di iterazione i , con $R_0 = 0.5$, $a = 0.5$ e $\alpha = 0.1$.

Nel primo grafico (1) si osserva che la dinamica converge per la funzione f_1 , mentre si blocca alla prima iterazione per la funzione f_2 , dato che il primo valore di R_1 ottenuto è negativo, per cui non si è in grado di continuare la dinamica ($I(R)$ dipende implicitamente da $\sqrt{R}$).

Confronto Dinamiche per $\alpha = 5.0$ e $x_0 = 0.5$




Figure 2: Andamento di R_i in funzione dell'indice di iterazione i , con $R_0 = 0.5$, $a = 0.5$ e $\alpha = 5.0$.

Nel secondo grafico (2) si osserva che la dinamica converge scegliendo la funzione f_2 , mentre si blocca alla prima iterazione per la funzione f_1 , poiché il primo valore di R_1 ottenuto è maggiore di 1, per cui non si è in grado di continuare la dinamica (f_2 dipende da $\sqrt{1 - R}$).

Di seguito, il plot di $|g'_a(R, \alpha)|$ calcolato in $R^*(\alpha)$, valore ottenuto interpolando i punti della curva $\alpha(R)$. Nell'immagine più in basso è presente anche il grafico di questi valori per $a = 0.5$. La linea rossa tratteggiata separa la zona in cui la condizione di convergenza è verificata da quella in cui non è più verificata.

Mappa di Convergenza per il Problema Quenched




Figure 3: Grafico di $|g'_a(R^*(\alpha), \alpha)|$ al variare di a e α . Nel grafico vengono evidenziate le curve di livello (in bianco) e la curva di a_{opt} al variare di α .

Si può osservare dalla figura (3) che, per valori fissati del parametro a , nessuna delle due funzioni garantisce la convergenza della mappa iterativa nell'intervallo $\alpha \in [0 : +\infty]$. In particolare, per la funzione f_1 non è garantita per α grandi, mentre per la funzione f_2 non è garantita per α piccoli.

5 Confronto tra Esperimenti e Teoria

Per risolvere l'equazione (1) tramite la procedura iterativa, è stato quindi adottato un approccio ibrido. Una volta fissati il parametro $a = 0.5$ e il valore di partenza $R_0 = 0.5$, la convergenza è stata raggiunta utilizzando la mappa definita con la funzione f_1 per valori di α minori di $\alpha_{thr} = 2$, mentre per valori maggiori è stata utilizzata l'analoga strategia con f_2 . Di seguito è riportato il grafico della curva di apprendimento per la teoria quenched (come $\epsilon(\alpha)$), sia in forma parametrica, sia attraverso i punti fissi della dinamica iterativa ibrida. Per completezza viene presentato, in maniera singola, lo stesso grafico anche per la teoria annealed.




Figure 4: Grafico della curva di apprendimento per la teoria quenched. Nel grafico viene presentato il valore ϵ^* (errore di generalizzazione) in funzione di α , taglia intensiva del dataset.




Figure 5: Grafico della curva di apprendimento per la teoria annealed. Nel grafico viene presentato il valore ϵ^* (errore di generalizzazione) in funzione di α , taglia intensiva del dataset.

Infine, viene riportato il grafico dei dati sperimentali confrontati con la curva parametrica e la soluzione numerica della teorie quenched e annealed.




Figure 6: Andamento di $\langle R \rangle$ in funzione di α . Confronto tra esperimenti realizzati per $N = 20$ e $N = 40$, e le curve teoriche: due ottenute in modo parametrico, le altre due ottenuta dai punti fissi della mappa iterativa al variare di α . La barra di errore dei punti medi è più piccola dei marker stessi.

Finalmente la curva teorica della teoria quenched si sovrappone ai dati sperimentali. La probabilità di campionare uno studente con errore di generalizzazione ϵ è proporzionale al volume di quella relativa regione nello spazio delle versioni. Inoltre la distribuzione degli ϵ , nel limite termodinamico, è dominata dal valore ϵ la cui regione è quella con volume maggiore (Ω^{typ}). Questo volume, a dataset fissato, coinvolge il prodotto di P contributi random; di conseguenza fare la media rispetto a tutti i possibili dataset (il rumore), per estrapolarne il comportamento tipico, non è un buon approccio, dato che per il prodotto di quantità random non vale il teorema del limite centrale, al contrario della loro somma (che si ottiene applicando il logaritmo). Per risolvere questo problema si utilizza un approccio quenched: il volume tipico dello spazio delle versioni dopo aver effettuato un addestramento con P punti non è $\Omega_P^{typ} \sim \langle \langle \Omega(\vec{\xi}^\mu, \vec{T}) \rangle \rangle$, bensì $\Omega_P^{typ} \sim \langle \langle \exp \left(\ln \left(\Omega(\vec{\xi}^\mu, \vec{T}) \right) \right) \rangle \rangle$, dove le doppie parentesi angolate indicano la media sulla distribuzione dei dataset e sulla distribuzione dei Teacher (nel nostro caso solo la prima dato che il Teacher è fisso).