

ESERCIZIO 6: La regola di Hebb e la regola del Perceptron.

Luca Cristofanilli 1999520

November 16, 2025

1 Predizioni analitiche

Con la regola di Hebb, svolgendo l'addestramento con un dataset di P punti, ognuno dei quali viene presentato una sola volta alla rete, il vettore dei coupling è dato da:

$$\vec{J}^H = \frac{1}{\sqrt{N}} \sum_{\mu} \vec{\xi}^{\mu} \sigma_T^{\mu}$$

Dopo varie considerazioni teoriche, si arriva ai seguenti risultati per l'errore di training e quello di generalizzazione:

$$\epsilon(\alpha) = \frac{1}{\pi} \arccos \left(\sqrt{\frac{2\alpha}{2\alpha + \pi}} \right)$$

e

$$\epsilon_{train}(\alpha) = 2 \int_0^{\infty} Dx H \left(\frac{1}{\sqrt{\alpha}} + \sqrt{\frac{2\alpha}{\pi}} x \right)$$

dove

$$H(u) = \int_u^{\infty} \frac{dy}{\sqrt{2\pi}} e^{-\frac{y^2}{2}}$$

2 Simulazioni numeriche e confronti con la teoria

L'esperimento per l'apprendimento di Hebb è stato svolto ripetendo la procedura di training 1000 volte, generando ad ogni esecuzione un teacher differente e un training set differente. Di seguito sono riportati i risultati della simulazione svolta con un test set costituito da $P_{test} = 1000$ punti per diversi valori di α , confrontati con le predizioni analitiche.




Figure 1: Confronto tra esperimenti e teoria per l'Hebb Learning. In figura sono riportati errore medio di training e errore medio di generalizzazione. Le barre di errore sono più piccole dei simboli stessi.




Figure 2: Confronto tra esperimenti e teoria per l'Hebb Learning. In figura sono riportati errore medio di generalizzazione, errore medio di training e la loro differenza. Le barre di errore sono più piccole dei simboli stessi.

La dinamica dell'apprendimento in funzione di α rivela un compromesso fondamentale. Nella regione a bassi valori di α (indicativamente $\alpha \lesssim 4$), il sistema manifesta la maggiore discrepanza tra l'errore di generalizzazione e l'errore di training. Tuttavia, questa stessa regione è caratterizzata dalla massima efficienza di apprendimento: la curva di generalizzazione presenta la sua pendenza più accentuata, indicando che ogni nuovo dato fornisce il massimo guadagno di informazione. Al contrario, nel regime asintotico di α grandi, il divario tra i due errori tende a zero. In questo limite, il modello raggiunge una generalizzazione robusta, dove la sua capacità di predizione su dati nuovi diventa molto simile alle sue prestazioni sul set di addestramento, la maggior parte dell'informazione è stata assorbita e la regola è stata appresa in modo ragionevole.

3 Regola del Perceptron

Infine, è stata svolta una simulazione con la regola di apprendimento del Perceptron (senza rumore additivo). La procedura è stata ripetuta 1000 volte, con diversi insegnanti, set di addestramento e set di test ($P_{test} = 1000$). In questo caso, la regola di apprendimento prevede che lo studente raggiunga un errore di addestramento nullo; di conseguenza, viene riportato solamente l'andamento di questa quantità in funzione di α , confrontato direttamente con i risultati della simulazione con la regola di Hebb e quelli delle simulazioni numeriche con la regola del Perceptron rumorosa (zero temperature Gibbs learning).




Figure 3: Confronto tra esperimenti e teoria. Andamenti delle teorie Annealed e Quenched, andamenti teorici dell'errore medio di generalizzazione e di training per la regola di Hebb. Dati sperimentali ottenuti dalle simulazioni per la regola di Hebb, la regola del Perceptron e quella del random Perceptron.

La curva delineata dai punti sperimentali ottenuti con la regola del Perceptron non rumorosa, si trova sistematicamente al di sotto della sua corrispettiva con aggiunta di rumore. Senza di questa, che permetteva allo studente di arrivare in una regione random dello spazio delle versioni ed effettuare un campionamento uniforme, si ha una sorta di "bias" che favorisce zone con errore di generalizzazione in media più basso.