

ESERCIZIO 7: La regole della Pseudo Inversa, Adaline e Bayes.

Luca Cristofanilli 1999520

November 23, 2025

1 Regola della Pseudo Inversa

L'idea della regola della pseudo inversa è di aggirare la nonlinearietà della funzione di attivazione, andando a lavorare sulle stabilità, definite come $\Delta^\mu(\vec{J}) = \vec{J} \vec{\xi}^\mu \sigma_T^\mu / \sqrt{N}$. Se l'esempio μ viene classificato correttamente, allora la $\Delta^\mu > 0$: più questo valore è grande, più lo studente $\vec{J}$ è "sicuro" della propria decisione e quindi ci si aspetta che l'errore di generalizzazione sia più basso. La regola prevede che tutte le Δ^μ siano uguali tra loro e uguali al valore κ , il più grande possibile, con $|\vec{J}|^2$ fisso. Geometricamente, questo corrisponde a trovare lo studente che forma il più piccolo angolo possibile con tutti i vettori del dataset di training. Questo è possibile, con vettori random, solamente se il numero di punti P è minore di N ($\alpha < 1$). Analogamente, si può riformulare il problema richiedendo che la norma di $\vec{J}$ sia la più piccola possibile con $\Delta^\mu = 1$ fissati. La componente di $\vec{J}$ che è ortogonale a tutti i $\vec{\xi}^\mu$ è influente nel calcolo delle stabilità e non fa altro che aumentare il valore della norma. Quindi, per mettersi nella condizione di norma minima, consideriamo solamente gli studenti che vivono nel sottospazio generato dai vettori $\{\vec{\xi}^\mu \sigma_T^\mu\}$. Con questa ipotesi, i vettori $\vec{J}$ sono della forma:

$$\vec{J}_{PI} = \frac{1}{\sqrt{N}} \sum_{\mu} x^\mu \vec{\xi}^\mu \sigma_T^\mu$$

Sostituendo all'interno della condizione $\Delta^\mu = 1$, si ha il seguente sistema di equazioni.

$$\frac{1}{N} \sum_{\nu} \vec{\xi}^\mu \cdot \vec{\xi}^\nu \sigma_T^\mu \sigma_T^\nu x^\nu = 1$$

Dove, definendo $C_{\mu\nu} = \frac{1}{N} \vec{\xi}^\mu \cdot \vec{\xi}^\nu \sigma_T^\mu \sigma_T^\nu$ si ha

$$\sum_{\nu} C_{\mu\nu} x^\nu = 1$$

per ogni μ . Se i vettori $\vec{\xi}^\mu$ sono statisticamente indipendenti, nel limite di N grande questi vettori saranno anche ortogonali e quindi linearmente indipendenti. Questo implica che la matrice $C_{\mu\nu}$ sia non singolare e il sistema abbia soluzione unica. In questo modo il vettore $\vec{J}_{PI}$ diventa:

$$\vec{J}_{PI} = \frac{1}{\sqrt{N}} \sum_{\mu\nu} (C^{-1})_{\mu\nu} \vec{\xi}^\mu \sigma_T^\mu$$

Quando $\alpha > 1$ è impossibile soddisfare la condizione $\Delta^\mu = \kappa$ per tutti i μ , dato che si sta cercando di risolvere un problema con P vincoli e $N < P$ gradi di libertà. Quando $\alpha \rightarrow 1$, per cercare di soddisfare l'uguaglianza $\Delta^\mu = 1$ per ogni μ , le performance di generalizzazione diminuiscono, lo studente sta overfittando sul training set e la sua norma diverge. Infatti, in questo limite le direzioni rimanenti si stanno saturando, i vettori tendono a essere linearmente dipendenti e quindi la matrice $C_{\mu\nu}$ tende ad essere singolare. Il suo determinante, e quindi almeno uno dei suoi autovalori, tende a zero. Calcolando la norma di $\vec{J}_{PI}$ si scopre che

$$|\vec{J}_{PI}|^2 = \frac{1}{N} \sum_{\mu\nu\alpha\beta} (C^{-1})_{\mu\nu} (C^{-1})_{\alpha\beta} \vec{\xi}^\alpha \cdot \vec{\xi}^\mu \sigma_T^\mu \sigma_T^\alpha = \sum_{\mu\nu\alpha\beta} (C^{-1})_{\mu\nu} (C^{-1})_{\alpha\beta} C_{\alpha\mu} = \sum_{\nu\beta} (C^{-1})_{\nu\beta}$$

Si può dimostrare che, con un dataset di vettori indipendenti tra loro, nel limite $N \gg 1$, la somma degli elementi della matrice $(C^{-1})_{\mu\nu}$ tende alla sua traccia. Cioè, nel limite termodinamico, vale la seguente relazione

$$|\vec{J}_{PI}|^2 = \sum_{\mu\nu} (C^{-1})_{\mu\nu} \simeq \text{Tr}(C^{-1}) = \sum_{\mu} \frac{1}{\lambda_{\mu}}$$

Nel limite $\alpha \rightarrow 1$, almeno uno degli autovalori $\lambda_{\mu} \rightarrow 0$ e quindi la norma $|\vec{J}_{PI}|^2 \rightarrow \infty$. Ricordando che il vettore $\vec{J}_{PI}$ soddisfa la relazione $\Delta^{\mu} = \vec{J} \cdot \vec{\xi}^{\mu} \sigma_T^{\mu} / \sqrt{N} = 1$, si ha che

$$\frac{|\vec{J}_{PI}| |\vec{\xi}^{\mu}| \sigma_T^{\mu} \cos(\theta_{\mu})}{\sqrt{N}} = 1$$

da cui

$$\cos(\theta_{\mu}) = \frac{\sigma_T^{\mu}}{|\vec{J}_{PI}|}$$

dove si è chiamato θ_{μ} l'angolo tra $\vec{J}_{PI}$ e $\vec{\xi}^{\mu}$ e viene usata la relazione $(\sigma_T^{\mu})^2 = 1$. In questo limite il vettore $\vec{J}_{PI}$ diventa asintoticamente ortogonale a tutti gli elementi del dataset $\vec{\xi}^{\mu}$ (anche se il prodotto scalare resta ben definito, $\vec{J}_{PI} \cdot \vec{\xi}^{\mu} = \sigma_T^{\mu} \sqrt{N}$). Per definizione, il vettore $\vec{T}$ deve essere tale da restituire per ogni μ un $\Delta^{\mu}(\vec{T}) = \vec{T} \cdot \vec{\xi}^{\mu} \sigma_T^{\mu} / \sqrt{N} > 0$, quindi deve avere una componente $\vec{T}_{||}$, appartenente allo spazio generato dai vettori del dataset, diversa da zero. Ai fini del calcolo dell'overlap, dato che il vettore $\vec{J}_{PI}$ vive in questo spazio, l'unica componente rilevante è $\vec{T}_{||} = \sum_{\mu} a_{\mu} \vec{\xi}^{\mu}$, dove gli a_{μ} sono diversi da zero per il ragionamento precedente. In questo modo, quando $|\vec{J}_{PI}| \rightarrow \infty$ si ha

$$R = \frac{\vec{J}_{PI} \cdot \vec{T}}{|\vec{J}_{PI}| |\vec{T}|} = \frac{\sum_{\mu} a_{\mu} \vec{J}_{PI} \cdot \vec{\xi}^{\mu}}{|\vec{J}_{PI}| \sqrt{N}} = \frac{\sum_{\mu} a_{\mu} \sigma_T^{\mu}}{|\vec{J}_{PI}|} \rightarrow 0$$

Da cui l'errore di generalizzazione tende a $\epsilon \rightarrow \frac{1}{2}$.

Gli esperimenti numerici sono stati realizzati ripetendo la procedura di addestramento $N_{runs} = 1000$ volte e calcolando l'errore di generalizzazione medio con test set di $P_{test} = 1000$ punti. Per $N = 20$ la matrice C comincia a essere singolare già da $P = 16$. Per ovviare a questo problema, sono stati utilizzati metodi di pseudoinversione per calcolare i restanti punti e arrivare a $\alpha = 1$. In $\alpha = 1$ il punto non tocca esattamente $\epsilon = 1/2$ e sicuramente questo effetto è dovuto al valore di N relativamente piccolo. Ripetendo l'esperimento per $N = 200$, il punto in $\alpha = 1$ si trova a un valore di ϵ sostanzialmente maggiore di quello ottenuto con $N = 20$, supportando l'ipotesi formulata in precedenza. Di seguito il grafico dell'errore di generalizzazione e dell'errore di training in funzione di α .




Figure 1: Errore medio di training e errore medio di generalizzazione con la regola della pseudo inversa per $N=20$.




Figure 2: Errore medio di training e errore medio di generalizzazione con la regola della pseudo inversa per $N=200$.

2 Regola Adaline

La regola Adaline si basa sul metodo dei minimi quadrati. Per minimizzare l'errore quadratico, si applicano tecniche di discesa lungo il gradiente alla funzione di errore

$$E(\vec{J}) = \frac{1}{2} \sum_{\mu} (\vec{J} \cdot \vec{\xi}^{\mu} - \sigma_T^{\mu})^2$$

da cui si ricava l'aggiornamento

$$\delta \vec{J} = -\gamma \frac{\partial E}{\partial \vec{J}} = \gamma \sum_{\mu} \vec{\xi}^{\mu} (\vec{J} \cdot \vec{\xi}^{\mu} - \sigma_T^{\mu})$$

Si può riformulare questa regola di apprendimento, definendo un nuovo vettore $\vec{J}' = \frac{\sqrt{N} \vec{J}}{|\vec{J}|}$, ben normalizzato $|\vec{J}'|^2 = N$, e introducendo un parametro κ tale che $\frac{1}{|\vec{J}|} = \kappa$.

$$E(\vec{J}') = \frac{1}{2\kappa^2} \sum_{\mu} (\Delta^{\mu} - \kappa)^2$$

In questa forma è evidente che, finché ci sono abbastanza gradi di libertà ($\alpha < 1$), questa regola coincide con la condizione imposta dalla regola della pseudo inversa, mentre per $\alpha > 1$ è la sua diretta generalizzazione. In questo secondo caso, non è possibile trovare un vettore che soddisfi la condizione $\Delta^{\mu} = k$ per ogni μ , quindi l'errore di training non è più nullo, ma in compenso non c'è più overfitting.

Gli esperimenti numerici sono stati realizzati ripetendo la procedura di addestramento $N_{\text{runs}} = 1000$ volte e calcolando l'errore di generalizzazione medio con test set di $P_{\text{test}} = 1000$ punti. Il learning rate $\gamma = 0.05$ risultava essere troppo grande per assicurare la convergenza dell'algoritmo, quindi questo valore è stato normalizzato rispetto a P , numero di punti che costituiscono il dataset della singola run. La discesa lungo il gradiente è proseguita finché la variazione di energia associata al passo sul vettore $\vec{J}$ non è diventata minore del valore di tolleranza impostato a $\text{tol} = 10^{-8}$. Per ottenere una maggiore sovrapposizione con i valori di errore di generalizzazione ottenuti con la regola della pseudo inversa, è stato impostato in un secondo momento un valore di tolleranza più piccolo, pari a $\text{tol} = 10^{-12}$. Di seguito, il grafico dell'errore di generalizzazione e dell'errore di training in funzione di α , i confronti con la regola della pseudo inversa.




Figure 3: Errore medio di training e errore medio di generalizzazione con la regola Adaline per N=20.




Figure 4: Errore medio di training e errore medio di generalizzazione con la regola Adaline per N=20. Approfondimento sulla regione $\alpha \in (0, 2]$.




Figure 5: Errore medio di training e errore medio di generalizzazione con la regola Adaline per N=20. Confronto con la regola della pseudo inversa.

3 Regola di Bayes

La regola di Bayes è quella che ci permette di minimizzare l'errore di generalizzazione utilizzando l'informazione disponibile in un modo statisticamente ottimale. Utilizzando il teorema di Bayes per stimare la probabilità a posteriori di avere un certo teacher $\vec{T}$ dato un certo dataset $\{\vec{\xi}^\mu, \sigma_T^\mu\}$, si ottiene una distribuzione uniforme. Infatti nella formula

$$P(\vec{T}|\{\vec{\xi}^\mu, \sigma_T^\mu\}) = \frac{P(\{\vec{\xi}^\mu, \sigma_T^\mu\}|\vec{T})P(\vec{T})}{P(\{\vec{\xi}^\mu, \sigma_T^\mu\})}$$

tutti i fattori sono uniformi. Per trovare lo studente ottimale, cerchiamo quello che in media massimizza l'overlap con $\vec{T}$.

$$R = \frac{1}{N} \frac{\int_{VS} d\mu(\vec{T}) \vec{J} \cdot \vec{T}}{\int_{VS} d\mu(\vec{T})}$$

Dato che $\vec{J}$ è fissato, può essere portato fuori dall'integrazione sullo spazio delle versioni, ottenendo quindi che lo studente che massimizza R è parallelo a $\langle \vec{T} \rangle_{VS}$. Per calcolare questo vettore quindi devo campionare uniformemente dallo spazio delle versioni, calcolare la media empirica dei vettori e poi normalizzarla in modo tale che $|\vec{J}_B| = \sqrt{N}$, calcolando in questo modo il centro di massa dello spazio delle versioni.

$$\vec{J}_B = \lim_{M \rightarrow \infty} \sqrt{N} \frac{\sum_{i=1}^M \vec{J}^{(i)}}{|\sum_{i=1}^M \vec{J}^{(i)}|}$$

Si ottiene che l'overlap di $\vec{J}_B$ con $\vec{T}$ è dato da $R_B = \vec{J}_B \cdot \vec{T} / N = \sqrt{R}$. Si può inoltre calcolare l'andamento teorico dell'overlap di Bayes tramite l'equazione autoconsistente

$$\frac{R_B^2}{\sqrt{1 - R_B^2}} = \frac{\alpha}{\pi} \int Dt \frac{\exp(-\frac{1}{2} R_B^2 t^2)}{H(-R_B t)}$$

Gli esperimenti numerici sono stati realizzati ripetendo la procedura di addestramento $N_{runs} = 1000$ volte e calcolando l'errore di generalizzazione medio con test set di $P_{test} = 1000$ punti. Il centro di massa è stato calcolato con $M = 100$ punti. Di seguito i grafici dell'andamento dell'errore di training e generalizzazione in funzione di α , con il relativo andamento teorico.




Figure 6: Errore medio di training e errore medio di generalizzazione con la regola di Bayes per $N=20$. Confronto con la curva sperimentale ottenuta in modo parametrico.

Infine, di seguito è presente il grafico riassuntivo, in cui vengono presentati i risultati di tutti gli esperimenti svolti finora, confrontati con i relativi andamenti teorici.

Per piccoli α le regole migliori sono Hebb, Adaline (Pseudo Inversa) e Bayes. Per grandi valori di α , le regole migliori sono la regola del Perceptron, la regola del Random Perceptron e la regola di

Confronto Completo: Esperimenti vs Teorie




Figure 7: Grafico riassuntivo di tutte le regole di apprendimento e tutti gli esperimenti svolti finora.

Bayes. Escludendo la regola di Bayes, quelle migliori per piccoli α hanno un andamento $\epsilon \sim \frac{1}{2} - k\sqrt{\alpha}$, ma purtroppo per valori asintoticamente grandi scalano come $\epsilon \sim \frac{1}{\sqrt{\alpha}}$. Al contrario, le regole migliori per grandi α hanno un andamento $\epsilon \sim \frac{1}{\alpha}$, mentre per piccoli valori sembrano avere un andamento lineare, quindi $\epsilon \sim \frac{1}{2} - k\alpha$ e tendono ad imparare meno velocemente. La migliore tra tutte è la regola di Bayes, che invece combina gli andamenti migliori, scalando come $\epsilon \sim \frac{1}{2} - k\sqrt{\alpha}$ per piccoli α e $\epsilon \sim \frac{1}{\alpha}$ per grandi α .